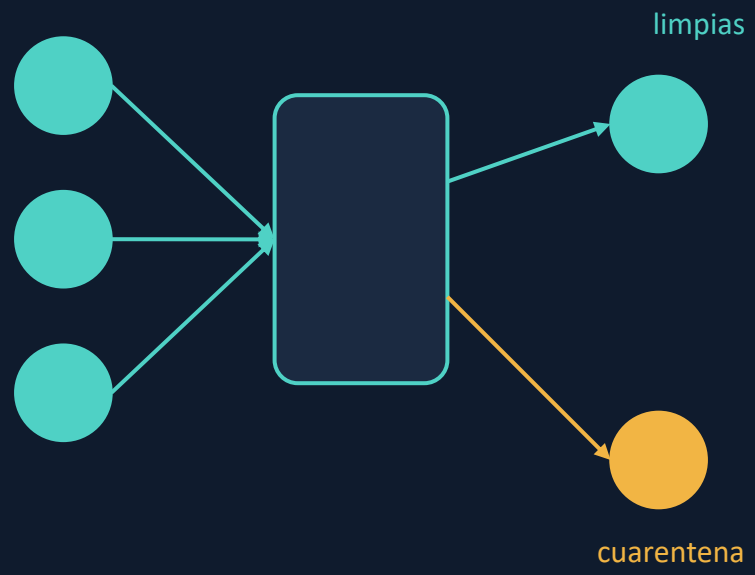
TECNOLÓGICO NACIONAL DE MÉXICO · CAMPUS COLIMA

Pipeline ETL robusto con zona de cuarentena



De datos crudos e inconsistentes a una base de datos confiable, sin que un registro corrupto detenga el lote.

Equipo

Angel Salvador Alvarez · Gael Alexandro Cortez Sarmienta · Sebastian Grageda Sandoval

Ingeniería de Datos (ATD-2602) · Unidad 2 · Grupo 1 Retail y e-commerce omnicanal
Prof. Armando Román Gallardo Heredia · 29 de octubre de 2026

EL PROBLEMA

Los datos reales llegan sucios y de varias fuentes

3

fuentes: catálogo CSV, ventas tienda CSV y ventas online JSON

1,220

registros crudos: 620 tienda física + 600 en línea

7

fases: diagnosticar, limpiar, integrar, validar y cargar

0

excepciones no controladas en todas las pruebas

Retos que trae el Grupo 1

- Duplicados del POS
- Fechas DD/MM, DD-MM, ISO y epoch
- Totales vacíos
- Precios en USD y MXN
- Correos malformados
- Bots con total ×80
- Productos que no existen

ARQUITECTURA

Siete fases encadenadas y ninguna fila se pierde

ENTRADA
Fuentes crudas
`datasets/`

→

FASES 0–2
Esquema, diagnóstico y faltantes
`fase1_fase2`

→

FASES 3–4
Outliers e integración
`fase3_fase4`

→

FASES 5–6
Escalar y validar
`fase5_fase6`

→

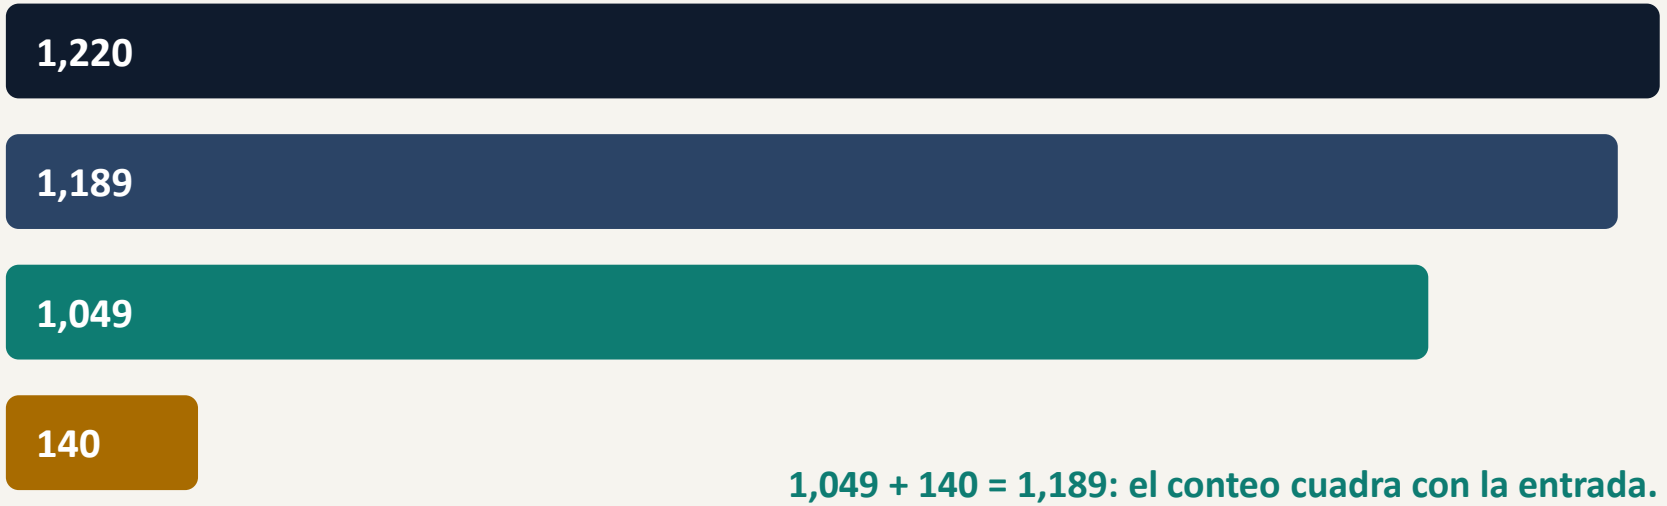
FASE 7
Carga a SQLite
`fase7_carga_bd`

Crudo
620 física + 600 online

Tras fases 1 a 4
−20 duplicados, −11 cantidades ≤ 0

transacciones_limpias
88.23 % del lote

cuarentena_errores
11.77 %, cada una con su motivo



1,049 + 140 = 1,189: el conteo cuadra con la entrada.

Limpiar sin inventar datos ni borrar ventas

1 · Diagnóstico

Medir antes de tocar

- Completitud, unicidad y tipos
- Vacíos ocultos ("N/A", "") que isna() no ve
- 20 duplicados exactos en tienda

2 · Faltantes

Clasificar y luego imputar

- MCAR o MAR con chi² y Bonferroni
- Si el dato existe, se recalcula: monto = cantidad × precio
- Mediana, no media; etiqueta ANONIMO en texto

3 · Outliers

Recortar, no borrar

- IQR × 1.5 con capping
- Máximo 2,109,055 → 16,510.02
- Solo se eliminan imposibles: 11 cantidades ≤ 0

¿Por qué mediana? En tienda la media del monto es 16,991 y la mediana 3,622: unos pocos extremos arrastran la media y la contagiarían a cada hueco que rellena.

Una fecha, una moneda, un catálogo y tres segmentos

Fechas a AAAA-MM-DD

Formatos explícitos por fuente, en hora de México. Si el epoch se tomara en UTC, 49 de 208 ventas caerían en otro día.

USD → MXN a 19.50

193 pedidos convertidos ANTES del IQR, para que los cuartiles no mezclen dólares con pesos.

Huérfanos contra el catálogo

merge con indicator: 27 en tienda y 33 en online. No se borran: se marcan y la Fase 6 decide.

Min-Max después del capping

Con el máximo sin recortar, el 99 % de las ventas quedaba bajo 0.01. Ahora la escala se reparte.

Terciles con qcut

Grupos de tamaño comparable; un corte fijo en pesos dejaría grupos vacíos.

Segmento	Filas	Rango (MXN)
BAJO	403	332.67 – 2,016.30
MEDIO	391	2,048.98 – 4,138.14
ALTO	395	4,183.67 – 16,510.02

Umbrales (19.50, IQR 1.5 y terciles) en config.yaml, versionado en git.

Datos que parecen correctos, pero son falsos

Reglas cruzadas (@model_validator)

R1	Llave de producto no huérfana
R2	Precio distinto de 500.00 (relleno del POS)
R3a	Sin bandera de bot (total ×80)
R3b	monto = cantidad × precio (±0.01)
R4	Cancelado o devuelto ⇒ facturable = 0
R5	Venta online exige correo válido

R3a nació del análisis forense: sin ella, 8 de 12 bots llegaban a la tabla limpia porque el capping ya había recortado su total.



FASE 7 Y ROBUSTEZ

Todo o nada en la base, y nada tumba el pipeline



Integridad declarada en SQLite: PRIMARY KEY, CHECK y NOT NULL. Prueba real: insertar cantidad = −99 dispara el CHECK, se aplica rollback y la tabla sigue con 1,049 filas.

0 / 25

excepciones en las pruebas de estrés de Pydantic

200

verificaciones con verdad conocida, 0 fallos

21

archivos rotos o raros (tortura), 0 excepciones

1 M

filas en 40 s en memoria; más de 5 GB por bloques

MÁS ALLÁ DE LO PEDIDO

Motor universal, umbrales versionados y prueba visual

1 Motor universal + panel

El profesor sube cualquier CSV, Excel, JSON o ZIP sin decir cómo se llaman sus columnas: el motor infiere tipos y aplica las 7 fases.

Sin internet ni librerías externas

2 Archivos de más de 5 GB

Se procesan por bloques en tres pasadas con parámetros globales: el resultado es idéntico al de memoria, byte a byte.

Probado: 5.29 GB, 18 M filas, cuarentena exacta

3 config.yaml versionado

Tipo de cambio, IQR, terciles y reglas en un archivo en git. Un error de dedo detiene la fase sin escribir nada.

Mismas cifras: 1,049 / 140

4 Pestaña Antes / después

Cada columna en crudo contra la tabla limpia: máximo 2.1 M → 16.5 k, 5 formatos de fecha → 1, 48 correos malos → 0.

La evidencia de cada regla

RESULTADO Y CIERRE

$4,074,888.52

MXN facturables sobre 1,049 ventas válidas · 77.7 % viene de la tienda física

1. El dato malo no se borra: se recorta, se marca o se aparta con su causa.
2. Las reglas de validación salen del análisis de los datos, no de suposiciones.
3. El resultado es auditable: 1,049 + 140 = 1,189, y la base lo demuestra.

Demo en vivo

`INICIAR_PANEL.bat`

1. Resumen: 1,049 y 140
2. Antes / después: monto_mxn
3. Prueba tu dataset: el archivo del profesor

¿Preguntas?