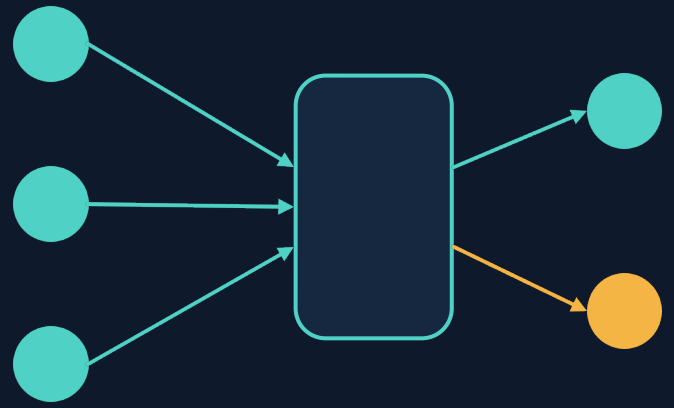
TECNOLÓGICO NACIONAL DE MÉXICO · CAMPUS COLIMA

Pipeline ETL robusto con zona de cuarentena



De datos crudos e inconsistentes a una base de datos confiable, sin que un registro corrupto detenga el lote.

Ingeniería de Datos (ATD-2602) · Unidad 2 · Grupo 1 Retail y e-commerce omnicanal

Prof. Armando Román Gallardo Heredia · Ago–Dic 2026

EL PROBLEMA

Los datos reales llegan sucios y desde varias fuentes

3

fuentes heterogéneas: catálogo CSV, ventas CSV y ventas JSON

1,220

registros crudos de venta: 620 en tienda física y 600 en línea

7

fases que diagnostican, limpian, integran, validan y cargan

0

excepciones sin controlar en las pruebas de estrés

Retos que trae el Grupo 1

- Duplicados del POS
- Fechas mixtas: DD/MM, ISO y epoch
- Nulos en totales
- Precios en USD y MXN
- Correos malformados
- Bots con compras gigantes

PRINCIPIO DE ROBUSTEZ EN PRODUCCIÓN

“Un pipeline no se evalúa porque funcione en el caso ideal. Se evalúa por lo que hace con el dato corrupto.”

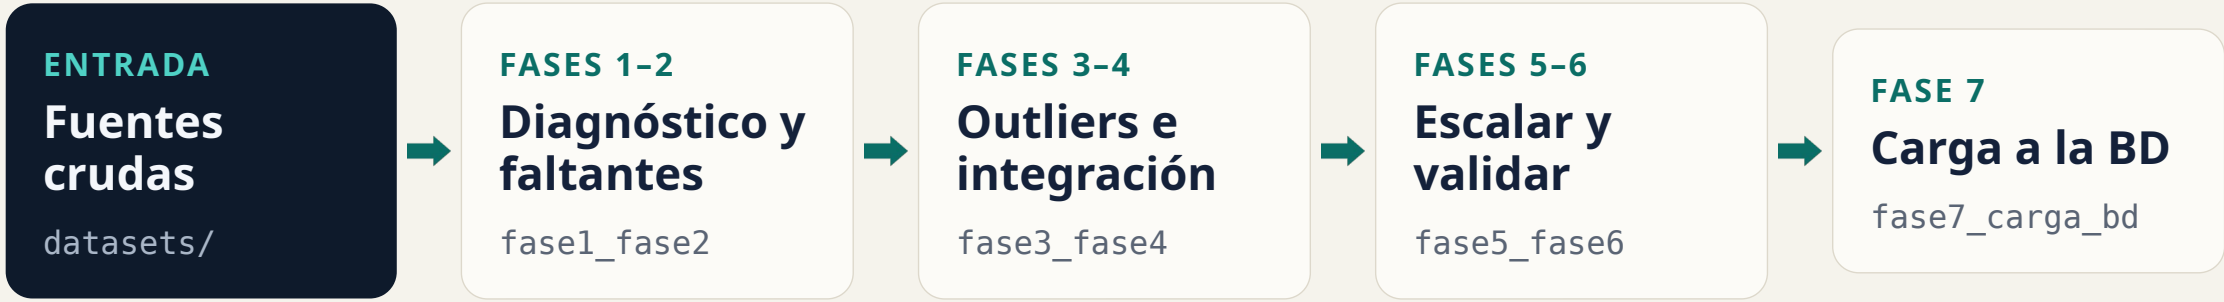
Sin crash

Trazabilidad auditable

Cuarentena con causa

ARQUITECTURA

Siete fases, cuatro scripts y una base de datos



Cada script lee el CSV que dejó el anterior y escribe su propia bitácora de auditoría.

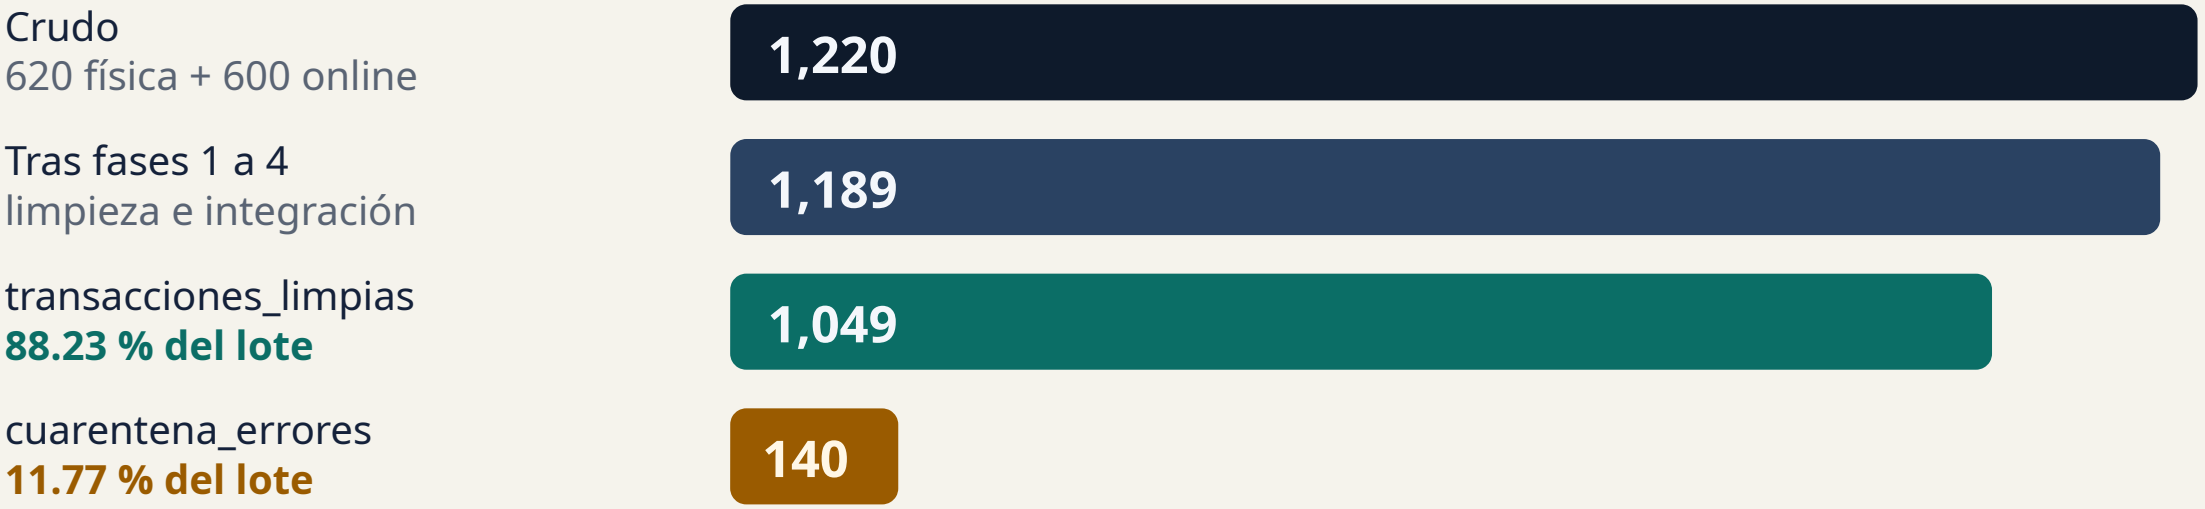
Al final, la base de datos **pipeline.db** recibe todo en dos tablas obligatorias.

`transacciones_limpias`
Registros que cumplen todo

`cuarentena_errores`
Registros rechazados con causa

FLUJO DE FILAS

De 1,220 registros crudos a 1,049 transacciones limpias



Se pierden 31 filas antes de validar: 20 duplicados exactos (Fase 2) y 11 cantidades imposibles (Fase 3). Después, **1,049 + 140 = 1,189**: el conteo cuadra con la entrada.

ORGANIZACIÓN DEL EQUIPO

Tres roles de ingeniería, tres entregables

INGENIERO/A 1 · FASES 1 y 2

Calidad, nulos y outliers

- Perfilado de completitud, unicidad y tipos
- Faltantes MCAR o MAR e imputación
- Outliers con IQR y capping

Entrega: funciones de limpieza y reporte antes y después.

INGENIERO/A 2 · FASES 3 y 4

Transformación e integración

- Fusión de CSV y JSON
- Fechas ISO y USD a MXN
- Cruce con catálogo, Min-Max y segmentos

Entrega: módulo de integración multifuente.

INGENIERO/A 3 · FASES 5, 6 Y 7

Validación, resiliencia y BD

- Esquemas Pydantic y cuarentena
- Commit y rollback en la base
- Pruebas de estrés con datos corruptos

Entrega: esquemas, script de carga y pruebas.

DATOS DE ENTRADA · GRUPO 1

Retail y e-commerce omnicanal: tres fuentes

Fuente	Tipo	Filas	Problemas que trae
catalogo_productos	CSV	50	Catálogo maestro sin nulos ni duplicados; es la fuente de verdad para el cruce.
ventas_tienda_fisica	CSV	620	20 duplicados exactos, 399 fechas no ISO, 31 totales vacíos, 11 cantidades ≤ 0.
ventas_online	JSON	600	208 timestamps epoch, 193 pedidos en USD, 12 bots con total ×80, 33 llaves huérfanas.

Dato clave: el cruce contra el catálogo detecta productos que no existen, y la fuente online mezcla formatos de fecha, monedas y estatus escritos de varias formas.

El código también soporta el Grupo 2 (ATM y transferencias); el repositorio incluye los datasets del Grupo 1.

FASE 1 · DIAGNÓSTICO DE CALIDAD INICIAL

Medir primero, antes de transformar nada

Completitud

Porcentaje de nulos por columna, incluidos los vacíos ocultos.

Unicidad

Conteo de duplicados exactos y duplicados por llave.

Tipos inferidos

Dtype de cada columna; avisa cuando mezcla tipos Python.

Lo que encontró el perfilado

20	duplicados exactos en la tienda física
5	correos vacíos (“”) que pandas no ve como nulos
20.48%	de id_cliente faltante en la tienda física
mixto	order_timestamp mezcla texto ISO y epoch entero

FASE 2 · MANEJO DE FALTANTES E IMPUTACIÓN

Primero se clasifica la ausencia, luego se imputa

MCAR
Falta al azar, sin relación con otras variables.

MAR
Falta según el valor de otra variable observada.

Cómo se decide
Chi-cuadrada y binomial con Bonferroni. Si algún p < 0.05, es MAR; si no, MCAR.

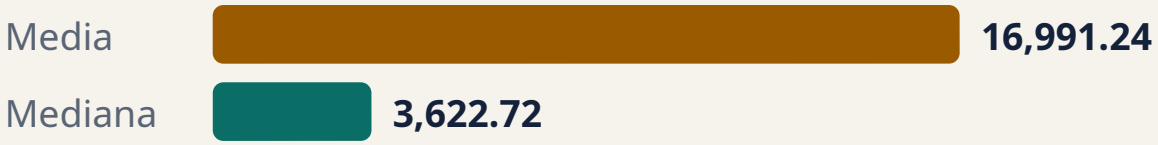
Columna	Faltantes	Mecanismo	Estrategia
monto_total_mxn	31 (5.17 %)	MCAR	Recalcular cantidad × precio
id_cliente	122 (20.33 %)	MCAR	Etiqueta ANONIMO
customer_email	20 (3.33 %)	MCAR	Etiqueta ANONIMO
shipping_address	77 (12.83 %)	MCAR	Etiqueta SIN_DIRECCION

Antes de imputar se eliminan los duplicados exactos y los vacíos ocultos se convierten en nulos reales. Cada fila guarda en campos imputados qué se rellenó.

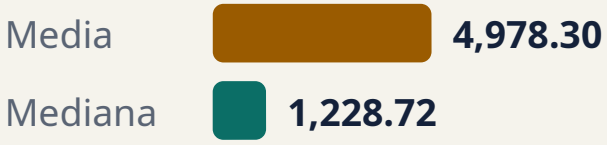
FASE 2 · JUSTIFICACIÓN ESTADÍSTICA

Por qué la mediana y no la media

Tienda física · monto_total_mxn



Tienda online · total_amount



Barras a la misma escala, en pesos.

Unos pocos extremos arrastran la media

13.85 asimetría en tienda

19.39 asimetría en online

Máximos: 2,109,055 MXN en tienda y 826,360.80 MXN en online.

La mediana ignora los extremos; la media los contagia a cada hueco que rellena. Donde el dato existe en otras columnas no se imputa: se recalcula exacto.

FASE 3 · OUTLIERS CON IQR

Se recortan los extremos y no se borran filas

Límites con IQR

IQR = Q3 − Q1

Límite sup. = Q3 + 1.5 × IQR

Capping

El valor se recorta al límite; la transacción se conserva.

Solo lo imposible se elimina

11 filas con cantidad ≤ 0 en la tienda física.

Columna	Q1	Q3	Límite sup.	Máx antes	Máx después	Recortados
tienda.cantidad	1	4	8	500	8	13
tienda.monto_total_mxn	2,012.82	7,811.70	16,510.02	2,109,055	16,510.02	40
online.total_amount	1,200.02	3,960.31	8,100.74	826,360.80	8,100.74	47

35 de los 47 pedidos online recortados no son bots: son compras reales y caras. Cada valor conserva su original en una columna **_original** y queda marcado con **flag_outlier**.

FASE 4 · INTEGRACIÓN Y UNIFICACIÓN

Un solo formato de fecha y una sola moneda

Fechas a YYYY-MM-DD

- Tienda: AAAA-MM-DD, DD/MM/AAAA y DD-MM-AAAA
- Online: texto ISO y epoch entero
- Epoch en segundos o milisegundos, según su tamaño

Todo se expresa en hora de México: 49 de 208 epoch caerían en otro día si se tomaran en UTC. Fechas no convertibles: 0.

USD a MXN a 19.50

- 193 pedidos online convertidos
- Se convierten unit_price y total_amount
- La moneda original y el valor sin convertir se conservan

Ejemplo ilustrativo: 100 USD × 19.50 = 1,950 MXN. Filas en USD después de convertir: 0.

Orden de las operaciones en las fases 3 y 4

Moneda | Mayúsculas | Imposibles | IQR | Fechas | Catálogo | Unificar

FASE 4 · CATÁLOGO MAESTRO Y HUÉRFANOS

Cruce con el catálogo y detección de huérfanos

1. Verificar que el catálogo no tenga llaves duplicadas: 0 duplicadas.
2. Cruzar las ventas contra el catálogo:
   `merge(how="left", indicator=True)`
3. Marcar con flag_huerfano las llaves que no existen. No se borran: se desvían en la Fase 6.

27 huérfanos en tienda física (4.58 %)

33 huérfanos en online (5.5 %)

Todos los de tienda traen precio_unitario = 500, un valor de relleno.

1,189 filas en unificado_grupo1.csv: 589 de tienda física y 600 online, con la columna canal.

FASE 5 · ESCALAMIENTO Y DISCRETIZACIÓN

Min-Max a [0, 1] y tres segmentos de monto

Min-Max

x_norm = (x − mín) / (máx − mín)

Se aplica a monto_mxn (332.67 a 16,510.02) y a cantidad (1 a 8). Sin recortar antes, el máximo era 2,109,055 y el 99 % de las ventas quedaba bajo 0.01.

Terciles con qcut

El catálogo mezcla precios muy distintos (Alimentos contra Electrónica). Un corte fijo en pesos dejaría grupos vacíos; los terciles dan tres grupos de tamaño comparable. Los cortes quedan en parametros_escalamiento.json.

Segmento	Registros	Rango real (MXN)	Promedio (MXN)
BAJO	403	332.67 – 2,016.30	1,139.72
MEDIO	391	2,048.98 – 4,138.14	3,008.55
ALTO	395	4,183.67 – 16,510.02	8,555.09

FASE 6 · VALIDACIÓN CON PYDANTIC

Un esquema estricto con validadores propios

```
class TransaccionLimpia(BaseModel):
@field_validator("id_producto")
@field_validator("correo")
@field_validator("fecha")
@field_validator("estatus")
@model_validator(mode="after")
def reglas_cruzadas(self): ...
```

Los de campo revisan un valor; el de modelo revisa combinaciones.

Regla	Qué exige
R1	Llave de producto no huérfana
R2	Precio distinto de 500.00 exacto (relleno)
R3a	Sin bandera de bot (total inflado ×80)
R3b	monto = cantidad × precio (±0.01), salvo outlier
R4	Cancelado o devuelto implica facturable = 0
R5	Venta online exige correo de contacto

Validadores de campo: id_producto con el patrón PROD-NNN, correo con regex anclado que rechaza “@@” y “..”, fecha dentro de 2026 y estatus dentro del catálogo de 6 valores.

FASE 6 · ANÁLISIS FORENSE

Datos que parecen correctos, pero son falsos

Código	Hallazgo	Afectados
E-01	Total distinto de cantidad × precio	12
E-02	Bots con total inflado ×80	12
E-03	Precio de relleno 500.00	29
E-04	Llaves huérfanas bien formadas	62
E-05	Correos como usuario@@gmail..com	11
E-06	Duplicados de negocio con otro folio	40
E-10	Cancelados con importe cobrado	119

Todos pasan una validación de tipo y formato.

Tres hallazgos cambiaron el diseño

E-09 · Capping incoherente

El validador respeta flag_outlier: el recorte lo hicimos nosotros.

E-02 · Bots

Nació R3a: sin ella, 8 de 12 bots llegaban a la tabla limpia.

E-10 · Cancelados

No se descartan: monto_facturable_mxn vale 0.

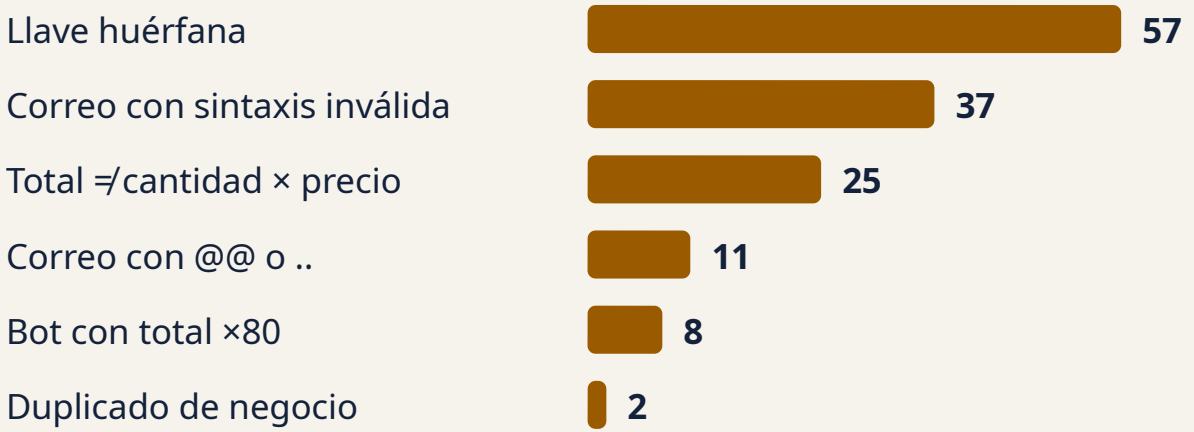
FASE 6 · ZONA DE CUARENTENA

Cada fila se valida aislada y nunca tumba el lote

```
for fila in filas:
try:
v = TransaccionLimpia(**fila)
limpias.append(v)
except ValidationError as e:
cuarentena.append(fila + motivo)
except Exception as e:
cuarentena.append(fila + error)
```

Versión simplificada del código real.

140 registros en cuarentena, por causa



Cada rechazo guarda motivo_rechazo_cuarentena y la regla violada. Verificación: **0 huérfanos** llegaron a transacciones_limpias.

FASE 6 · PRUEBAS DE ESTRÉS

25 casos corruptos y ningún colapso

25
casos inyectados a propósito

24
rechazados con mensaje explícito

1
caso de control válido, aceptado

0
excepciones no controladas

Qué se inyectó

- Texto en campos numéricos
- Cantidades negativas y cero
- Fecha 31/02
- Fechas en 1999 y 2099
- Id mal formado
- Llave huérfana
- Precio de relleno
- Total inflado ×80
- Correo con doble arroba
- Canal inexistente
- Estatus fuera de catálogo
- Segmento inválido
- Normalizado fuera de rango
- Campo obligatorio ausente
- Fila completamente nula

FASE 7 · CARGA TRANSACCIONAL A SQLITE

Todo o nada: commit si sale bien, rollback si falla



abre la transacción · evita duplicar filas · inserta el lote · confirma los cambios · ante cualquier error

Integridad en el esquema

- PRIMARY KEY en id_registro
- CHECK en cantidad, precios, rango [0, 1], canal y segmento
- GLOB para el formato PROD-NNN
- NOT NULL en lo que el negocio exige

Prueba de rollback

Se inserta una fila con cantidad = −99, que viola el CHECK. Se captura el IntegrityError y se aplica rollback.

Conteo antes y después: 1,049. Tabla intacta.

Tablas finales: 1,049 + 140 = 1,189 filas.

RESULTADO DE NEGOCIO

Lo que queda en la base de datos es confiable

$4,074,888.52

MXN facturables sobre 1,049 ventas válidas

77.7 %

del importe viene de la tienda física

265

pedidos ALTO en física superan a todo el online

Canal	BAJO	MEDIO	ALTO	Total
FÍSICA	$163,169.40 · 134	$480,872.27 · 161	$2,521,190.44 · 265	$3,165,232.11 · 560
ONLINE	$138,963.91 · 202	$354,570.17 · 192	$416,122.33 · 95	$909,656.41 · 489

Cada celda: monto facturable en MXN · número de pedidos. Los pedidos cancelados o devueltos se conservan, pero facturan 0.

RÚBRICA OFICIAL · BASE 100 PUNTOS

Cómo cumple el proyecto cada criterio

Criterio técnico	Pts	Evidencia en el proyecto
Mockup y reglas de negocio	10	REGLAS_DE_NEGOCIO.md: decisión, motivo y efecto
Calidad de datos	20	MCAR/MAR, mediana, IQR con capping y columnas _original
Integración y transformación	20	Fechas ISO, USD a MXN, cruce, Min-Max y terciles
Validación Pydantic y cuarentena	20	Validadores de campo y modelo; 140 con motivo
Persistencia y transacciones	15	Commit y rollback, CHECK, 2 tablas, rollback probado
Resiliencia y defensa oral	15	25 casos de estrés, 0 excepciones; defensa individual
Total	100	60 % del Portafolio Digital de la Unidad 2

CIERRE

Conclusiones

1. El dato malo no se borra: se recorta, se marca o se aparta con su causa.
2. Las reglas de validación salen del análisis de los datos, no de suposiciones.
3. El resultado es auditable: 1,049 + 140 = 1,189, y la base lo demuestra.

Cómo ejecutarlo, en orden

```
python fase1_fase2_pipeline.py
python fase3_fase4_pipeline.py
python fase5_fase6_pipeline.py
python fase7_carga_bd.py
```

Cada script recibe la carpeta de entrada y la de salida.

¿Preguntas?